

관공서 Q&A 챗봇 시스템 고도화

1. LLM-AS-A-EVAL 벤치마크에서 성능 최대 22% 및 응답 속도 66% 개선

- Chain-of-Thought(CoT) 및 DeepEval Synthesizer 기반 골든 데이터 세트 구축으로 복합적인 질의 상황을 다룸
- Supervised-Fine-Tuning(SFT) 기법 적용으로 질의-응답 답변 형식 불일치 문제 개선

$$RAGAS_e = \frac{AnswerCorrectness_e + Faithfulness_e + AnswerRelevancy_e}{3}$$

$$Response\ Time_e = \frac{\max_{1 \leq i \leq N_e} T_{e,i}^{end} - T_e^{start}}{N_e}$$

실험 ID	기법	데이터셋	Iterations (↓)	평가 모델	Answer Correctness (↑)	Faithfulness (↑)	Answer Relevancy (↑)	Response Time (↓)
Exp1	Exaone-3.5-7.8B-Instruct	Base Dataset	-	Qwen-2.5-32B-Instruct-AWQ	0.4609	0.1583	0.1931	0.66
Exp2	Exaone-3.5-7.8B-Instruct+SFT	Base Dataset	10	Qwen-2.5-32B-Instruct-AWQ	0.5889	0.4859	0.3111	0.53
Exp3	Exaone-3.5-7.8B-Instruct+SFT	CoT Dataset (Ours)	10	Qwen-2.5-32B-Instruct-AWQ	0.6447 (+9.48%)	0.5255 (+8.15%)	0.3922 (+26.07%)	0.42 (-20.75%)
Exp4	Exaone-3.5-7.8B-Instruct+SFT	DeepEval Dataset (Ours)	10	Qwen-2.5-32B-Instruct-AWQ	0.7284 (+23.69%)	0.5398 (+11.09%)	0.4274 (+37.38%)	0.18 (-66.04%)

2. 응답 지연 병목 완화, 외부 도구 및 인터페이스 표준화

- vLLM 기반 비동기 병렬 추론 파이프라인 구축으로 응답 지연 병목 완화
- Model-Context-Protocol(MCP) 구조 적용으로 외부 도구 및 컨텍스트 연동 인터페이스 표준화

